Plan inicial de proyecto

Clasificación automática de consultas de atención al cliente mediante modelos de lenguaje

Planteamiento del problema

Los canales digitales de atención al cliente de una empresa de ecommerce reciben diariamente una gran cantidad de consultas escritas relacionadas con distintos motivos, como problemas con pagos, envíos, devoluciones, acceso a una cuenta o consultas sobre productos.

La clasificación manual de estas consultas puede demandar tiempo y recursos, especialmente cuando el volumen de interacciones es elevado. Poder identificar automáticamente el motivo principal de cada consulta puede facilitar su organización, derivación al área correspondiente y su posterior análisis.

El objetivo de este proyecto es desarrollar y evaluar una solución basada en **Procesamiento de Lenguaje Natural mediante un Large Language Model (LLM)** capaz de clasificar consultas de atención al cliente en un conjunto previamente definido de categorías.

Se utilizará las siguientes categorías:

- **Pagos y cobros**
- **Envíos y entregas**
- **Devoluciones y reembolsos**
- **Cuenta y acceso**
- **Productos y publicaciones**

Cada consulta tendrá una intención principal y deberá ser asignada por el modelo a una única categoría.

El proyecto estará orientado principalmente a analizar la capacidad de un modelo de lenguaje para comprender el contenido semántico de las consultas y determinar correctamente su intención mediante distintas estrategias de prompting.

Métodos a utilizar

El proyecto se desarrollará utilizando **Python**, principalmente en un entorno como Google Colab o Jupyter Notebook.

La clasificación será realizada utilizando un **Large Language Model (LLM)** al que se le proporcionará cada consulta junto con instrucciones que indiquen las categorías posibles.

En una primera etapa se utilizará una estrategia de **zero-shot prompting**, en la que el modelo recibirá una instrucción con la tarea a realizar, el transcript de la conversación que debe clasificar y el conjunto de categorías posibles junto con una breve descripción de cada una.

El objetivo será que el modelo interprete el contenido de la conversación y determine cuál de las categorías representa mejor el motivo principal de contacto del cliente.

De esta manera, el modelo no dependerá únicamente del nombre de cada categoría, sino que contará con una descripción explícita de los criterios asociados a cada una.

También se buscará mantener una salida estructurada y controlada, solicitando al modelo que responda exclusivamente con una de las categorías permitidas. Esto facilitará la comparación automática entre la categoría predicha por el modelo y la categoría esperada en el dataset.

Las principales herramientas previstas son:

- Python.
- **pandas** para manipulación del dataset.
- API a un Large Language Model.
- Librerías de Python para cálculo de métricas y visualización de resultados.
- **matplotlib** para gráficos y matrices de confusión.

No se realizará entrenamiento de un modelo propio. El análisis estará centrado en el uso de modelos de lenguaje previamente entrenados y en el diseño de los prompts utilizados para resolver la tarea.

Dataset

Se utilizará un dataset sintético desarrollado específicamente para este proyecto, evitando trabajar con información privada o proveniente de conversaciones reales de atención al cliente.

El dataset estará compuesto por aproximadamente 50.000 conversaciones en español, distribuidas de manera balanceada entre las cinco categorías definidas, con aproximadamente 10.000 conversaciones por categoría.

Cada conversación estará formada por entre dos y cuatro turnos de diálogo entre un cliente y un agente de atención, buscando representar de manera sencilla distintas situaciones habituales dentro de un servicio de soporte.

Resultados esperados

Se espera que el modelo de lenguaje sea capaz de identificar correctamente la intención principal de la mayoría de las consultas y asignarlas a alguna de las cinco categorías establecidas.

Para evaluar los resultados se utilizarán métricas estándar de clasificación, principalmente:

- **Accuracy**
- **Precision**
- **Recall**
- **F1-score**

También se generará una **matriz de confusión** para identificar qué categorías presentan mayores dificultades o cuáles tienden a confundirse entre sí.

Los resultados serán presentados mediante tablas, métricas y gráficos comparativos.

Además del rendimiento cuantitativo, se realizará un análisis cualitativo de algunos errores de clasificación para identificar situaciones en las que el modelo pueda presentar dificultades, por ejemplo consultas ambiguas, mensajes poco claros o textos que podrían relacionarse con más de una categoría.